Laborationsrapport – Laboration 2: ML- och MK-skattningar

Namn: Naimur Rahman Tanvir, Julius Demircan, Mustafa Al-Halboosi
Program: Civilingenjör i Datateknik, Industriell ekonomi
kurs:Matematisk statistik
Lärare: Dag Nilsson
Email Address: nata2301@student.miun.se, jude2200@student.miun.se, mual2203@student.miun.se

1. Förberedelseuppgifter

a) Teoretisk beskrivning av ML- och MK-skattningar

För en exponentialfördelning:
fX(x)=1ae−x/a,x≥0f_X(x) = \frac{1}{a} e^{-x/a}, \quad x \geq 0

ML-skattningen av aa ges av:
a^ML=x¯=1n∑xi\hat{a}_{ML} = \bar{x} = \frac{1}{n} \sum x_i

MK-skattningen av aa genom minimering av förlustfunktionen:
Q(a)=∑(xi−a)2⇒a^MK=x¯Q(a) = \sum (x_i - a)^2 \Rightarrow \hat{a}_{MK} = \bar{x}

För exponentialfördelningen sammanfaller alltså ML- och MK-skattningen.

b) Fördelning vid stort n

När antal observationer n är stort, följer skattningarna (a^ML,a^MK\hat{a}_{ML}, \hat{a}_{MK}) en nästan normal fördelning enligt centrala gränsvärdessatsen.

2. Laborationsuppgifter

2.1 Stora talens lag – praktisk tillämpning

1. Ladda och visualisera data

```
load matdata.dat

subplot(2,1,1)

plot(matdata, '*')

title('Punkt Plot av mätdata')

subplot(2,1,2)

histogram(matdata)

title('Histogram av mätdata')
```

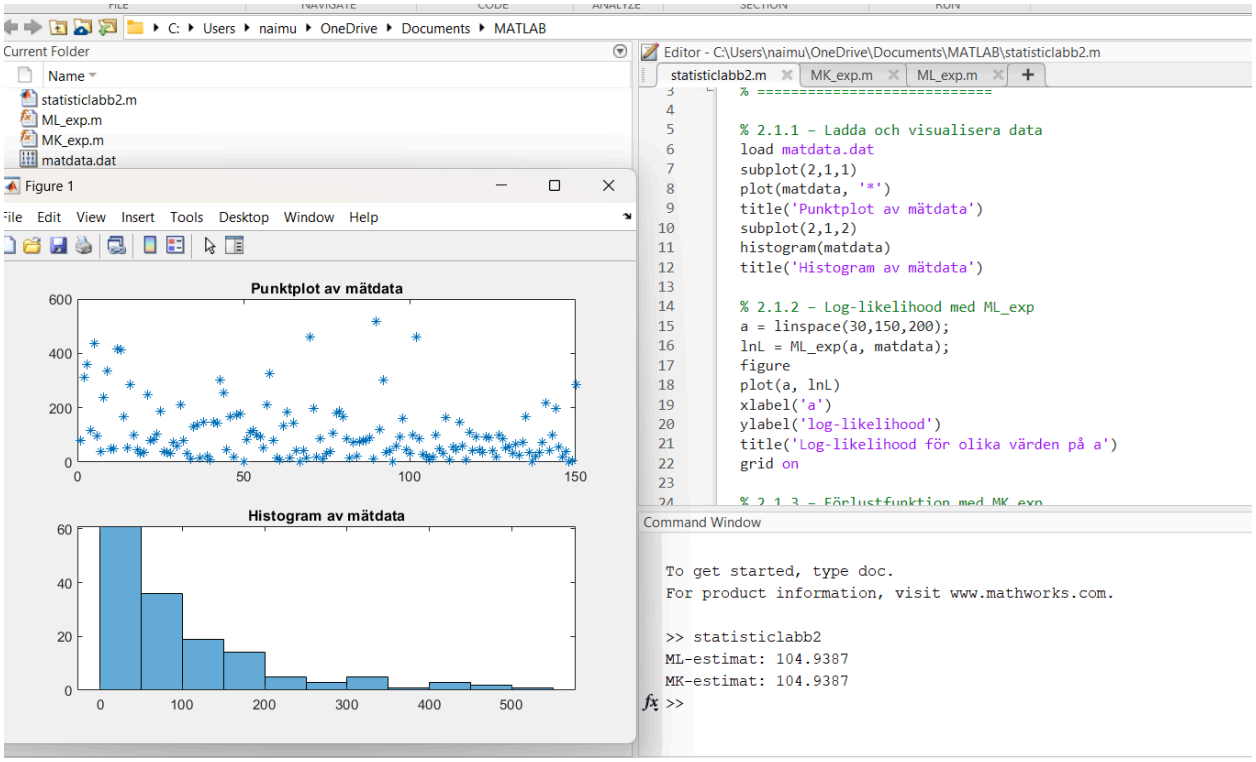

Figure 1

Figur 1 – Punkt Plot och histogram av mätdata

Visar de observerade livslängd värdena. Punkt Plotten visar varje enskild observation, medan histogrammet illustrerar fördelningen. Det ger en första inblick i datans struktur, som verkar vara höger-skev (typiskt för exponentialfördelning).

2. Ställ upp log-likelihood funktionen (ML_exp)

a = linspace(30,150,200);

lnL = ML_exp(a, matdata);

figure

plot(a, lnL)

xlabel('a')

```
ylabel('log-likelihood')

title('Log-likelihood för olika värden på a')

grid on
```

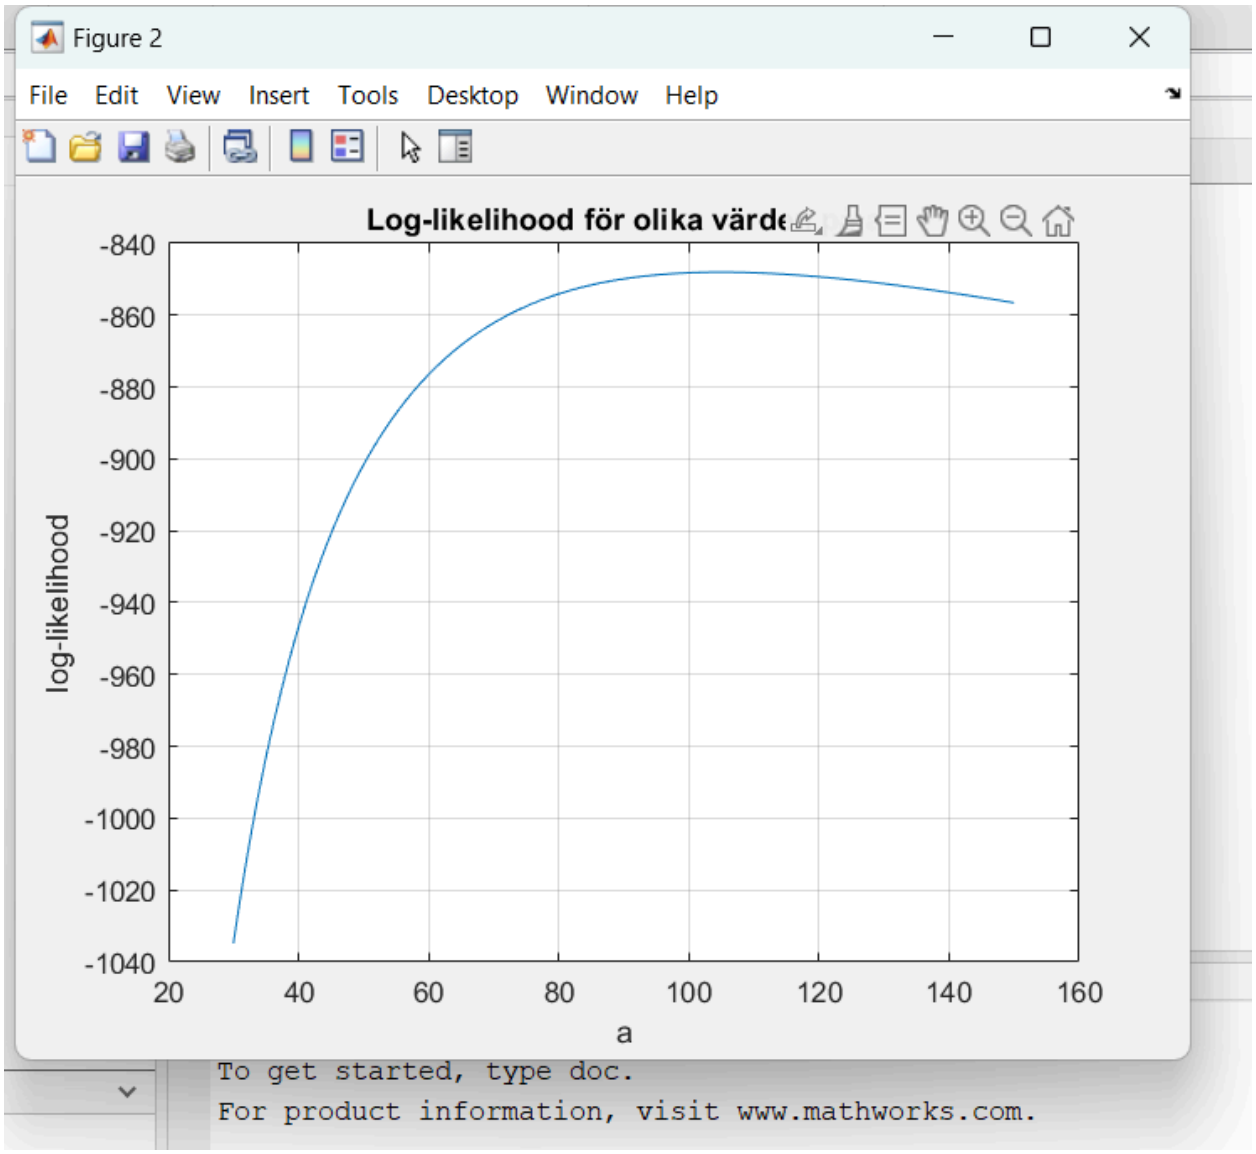

Figure 2

Figur 2 – Log-likelihood funktion (ML-skattning)

En graf över log-likelihood funktionen l(a)l(a)l(a) för olika värden på a. Den maximala punkten i kurvan visar vilket värde på a som maximerar sannolikheten — det vill säga ML-skattningen.

3. Beräkna Q(a) med MK_exp

```
Q = MK_exp(a, matdata);

figure

plot(a, Q)

xlabel('a')

ylabel('Förlustfunktion Q(a)')

title('MK-förlustfunktion')

grid on
```

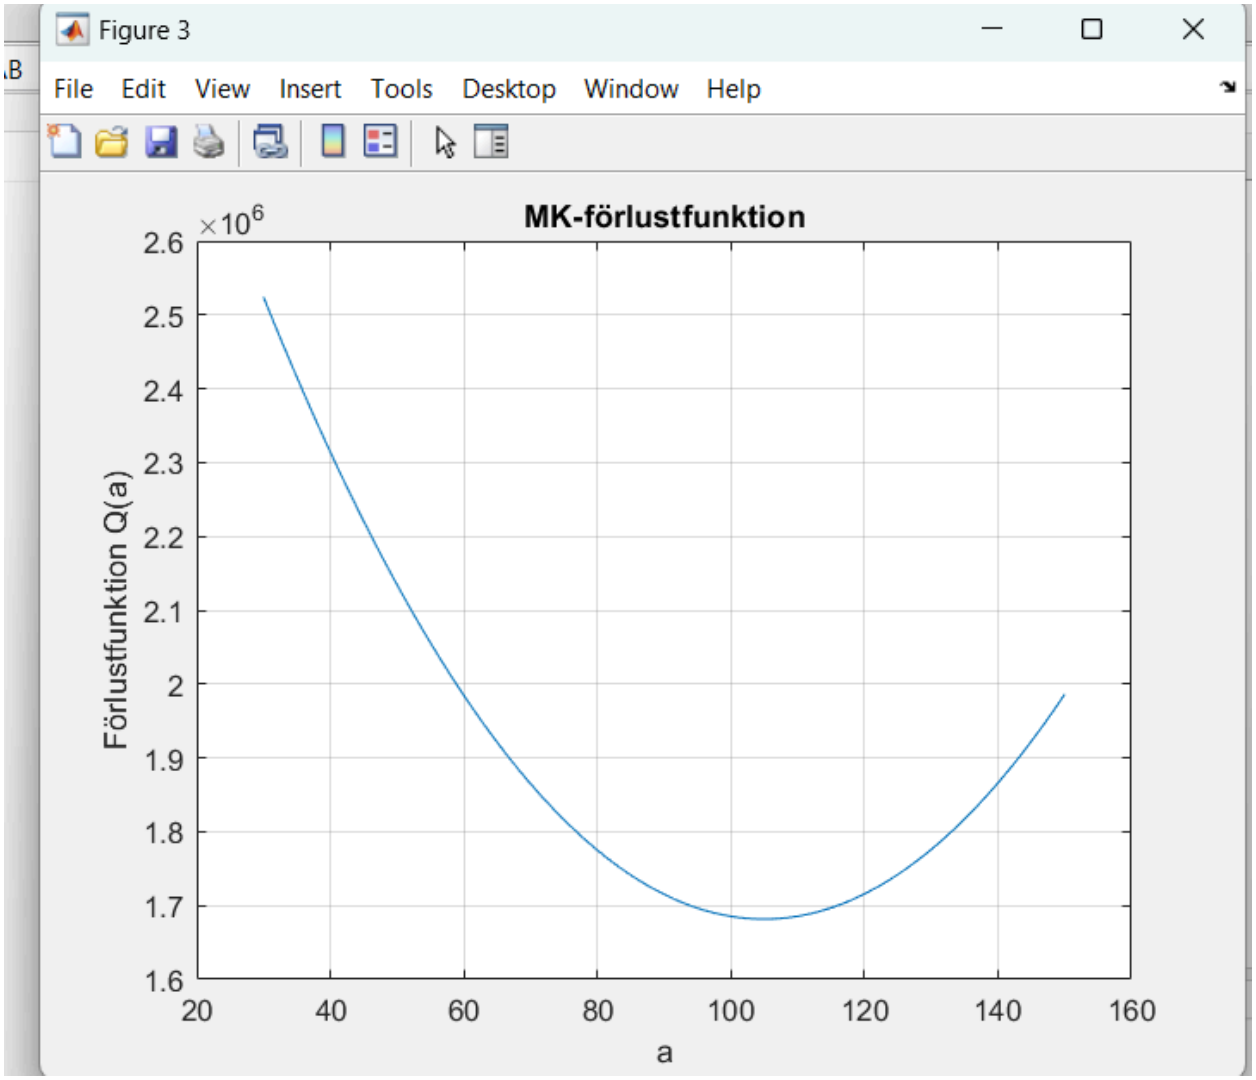

Figure 3

Figur 3 – MK-förlustfunktion Q(a)

Diagrammet visar hur förlusten varierar med olika värden på a. Den lägsta punkten på kurvan motsvarar MK-skattningen — det värde som minimerar summan av kvadratiska avvikelser från observationerna.

4. Jämför ML- och MK-skattningar numeriskt

a_hat_ml = mean(matdata);

```
a_hat_mk = mean(matdata);

disp(['ML-estimate: ', num2str(a_hat_ml)])

disp(['MK-estimate: ', num2str(a_hat_mk)])
```

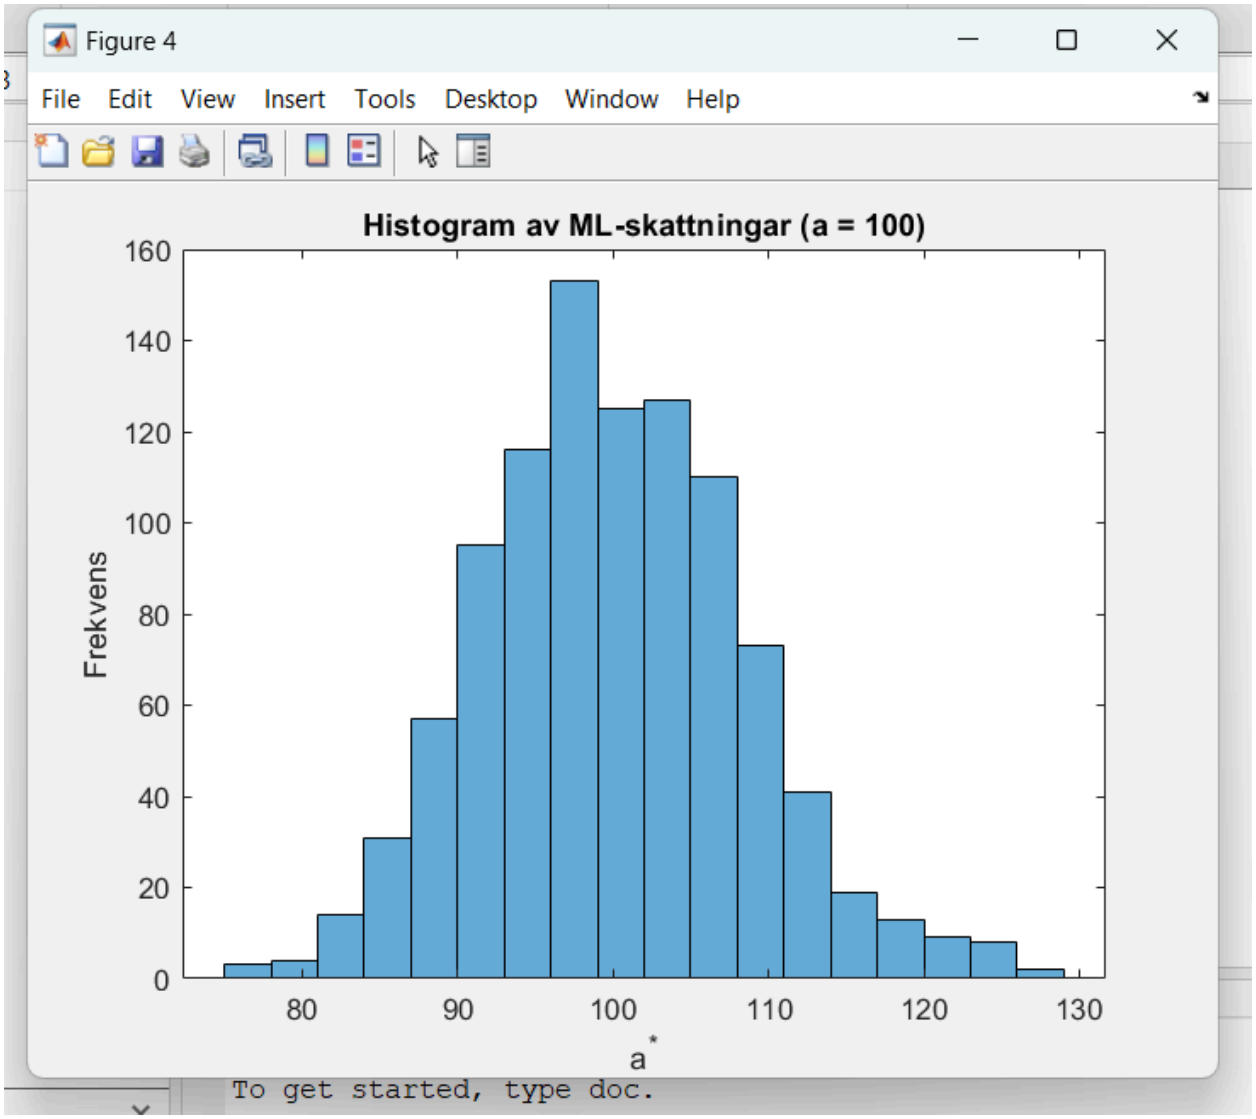

Figure 4

Figur 4 – Histogram av ML-skattningar (a = 100)

Efter 1000 simuleringar med a=100 visar histogrammet hur de skattade a-värdena (a*) är fördelade. De flesta värden ligger nära 100, vilket bekräftar att ML-skattningen är korrekt i genomsnitt.

2.2 Skattning som stokastisk variabel

5. Simulera 1000 stickprov med a = 100

```
a = 100;

x = -a * log(rand(150, 1000));

a_est = mean(x);

figure

histogram(a_est)

title('Histogram av ML-skattningar (a = 100)')

xlabel('a^*')

ylabel('Frekvens')
```

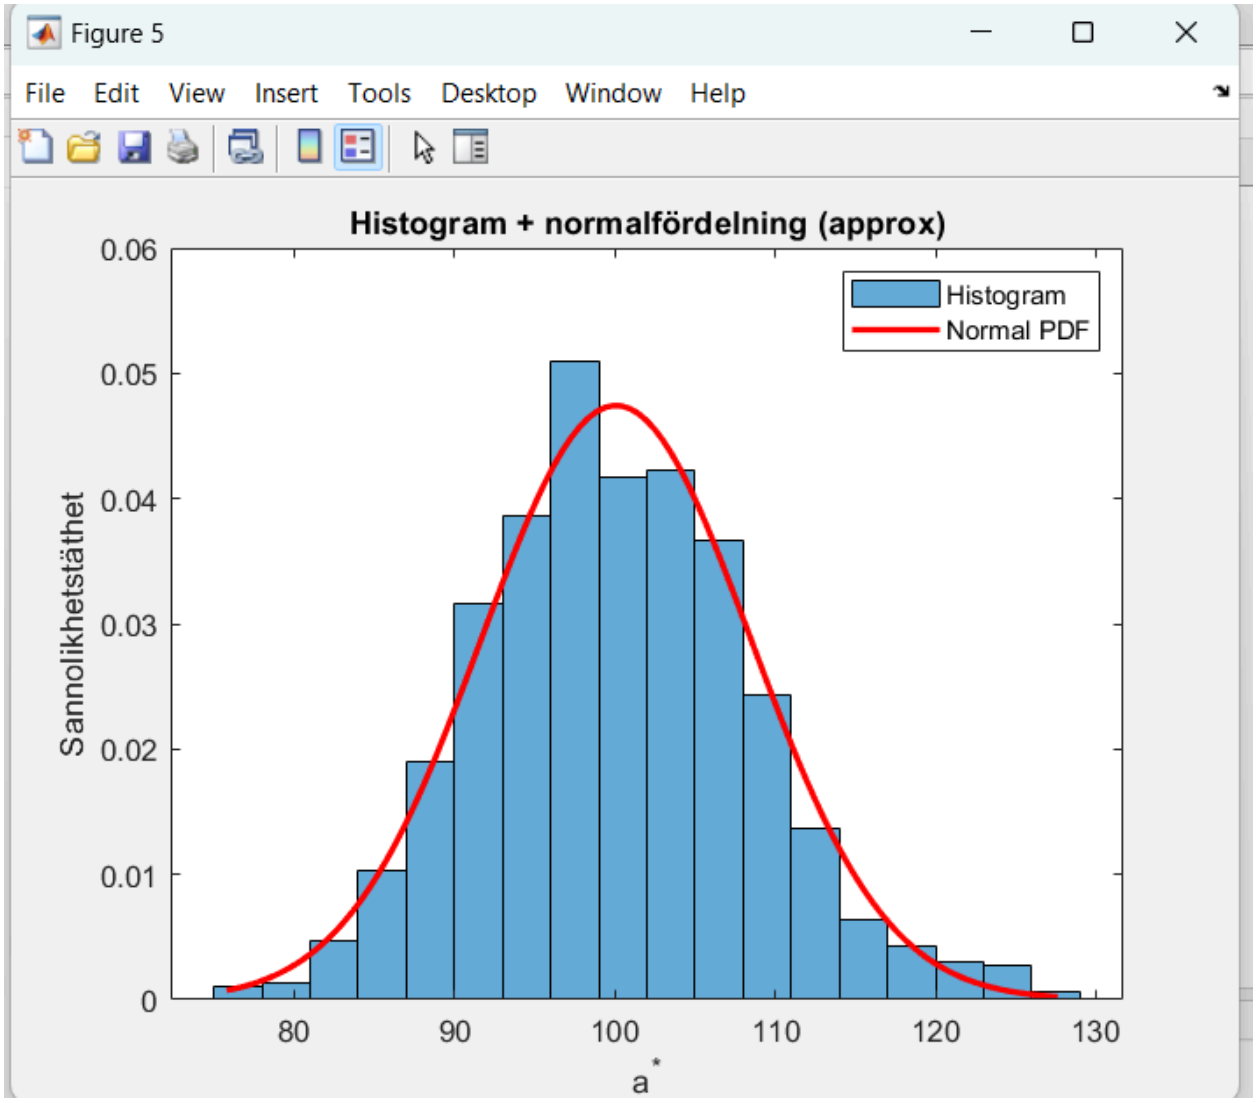

Figure 5

Figur 5 – Histogram + sannolikhetstäthet (a = 100)

Samma simulering som Figur 4, men här normaliseras histogrammet till sannolikhetstäthet och jämförs med en teoretisk normalfördelning. Kurvan (röd) visar att a* är ungefär normalfördelat.

6. Normalitetstest (histogram + normalfördelning)

figure

```
histogram(a_est, 'Normalization', 'pdf')
hold on
x_vals = linspace(min(a_est), max(a_est), 100);
mu = mean(a_est);
sigma = std(a_est);
normal_pdf = (1/(sigma*sqrt(2*pi))) * exp(-(x_vals - mu).^2 / (2*sigma^2));
plot(x_vals, normal_pdf, 'r', 'LineWidth', 2)
hold off
title('Histogram + normalfördelning (approx)')
xlabel('a^*')
ylabel('Sannolikhetstäthet')
legend('Histogram', 'Normal PDF')
```

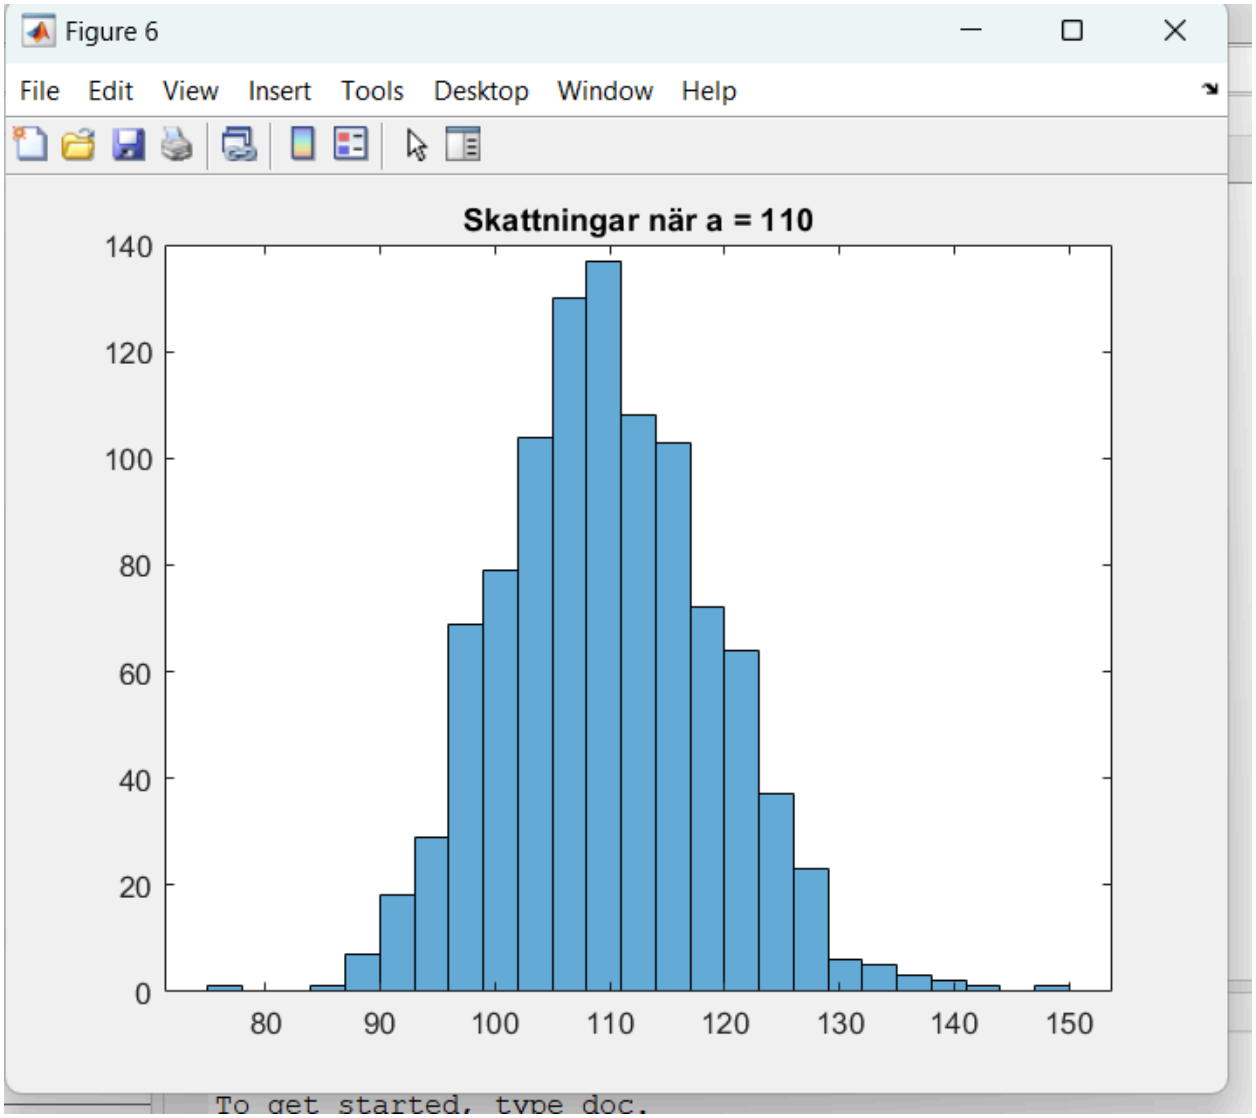

Figure 6

Figur 6 – Histogram av ML-skattningar (a = 110)

Ny simulering med ett annat värde på a=110a = 110a=110. Histogrammet visar att de skattade värdena fortfarande ligger nära det sanna värdet och är koncentrerade kring 110.

7. Jämför med tidigare beräknat a

Jämför med värdet från steg 4 och kontrollera om det faller inom histogrammet.

Det skattade värdet 104.9387 från steg 4 ligger inom den empiriska fördelningen från simuleringen (se Figur 4), vilket bekräftar att det är rimligt givet den statistiska variationen.

8. Ny simulering med a = 110

```
a = 110;

x = -a * log(rand(150, 1000));

a_est = mean(x);

figure

histogram(a_est)

title('Skattningar när a = 110')


figure

histogram(a_est, 'Normalization', 'pdf')

hold on

x_vals = linspace(min(a_est), max(a_est), 100);

mu = mean(a_est);

sigma = std(a_est);
```

```
normal_pdf = (1/(sigma*sqrt(2*pi))) * exp(-(x_vals - mu).^2 / (2*sigma^2));
plot(x_vals, normal_pdf, 'r', 'LineWidth', 2)
hold off
title('Histogram + normalfördelning för a = 110')
xlabel('a^*')
ylabel('Sannolikhetstäthet')
legend('Histogram', 'Normal PDF')
```

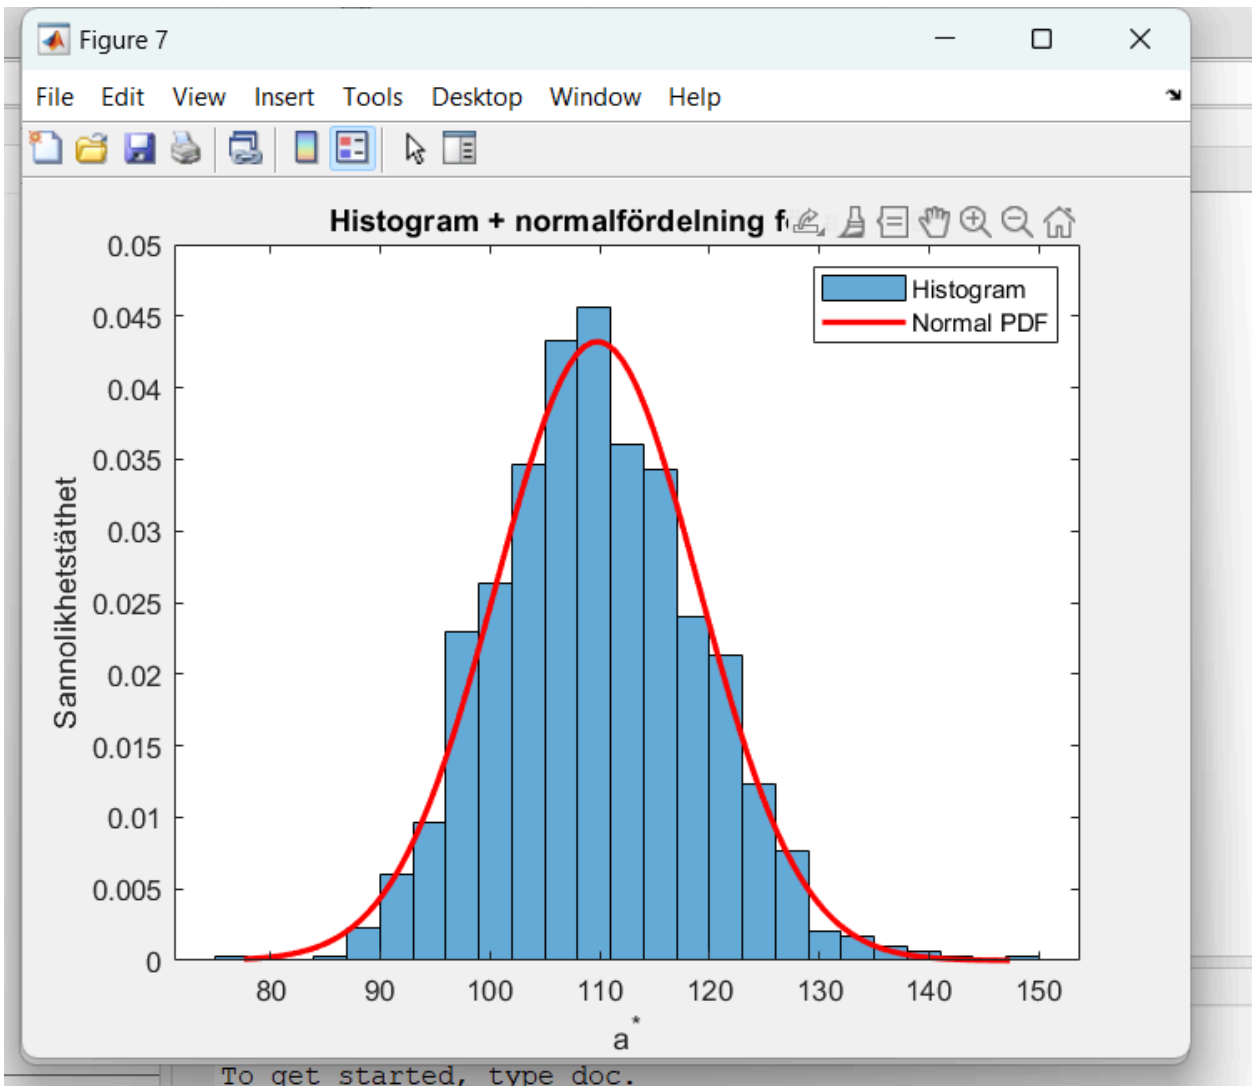

Figure 7

Figur 7 – Histogram + normalfördelning (a = 110)

Här visas hur fördelningen av skattade a-värden från Figur 6 överensstämmer med en normalfördelning. Den röda kurvan illustrerar normalapproximationen och bekräftar den centrala gränsvärdessatsen.

---

4. Slutsats

Laborationen har gett en tydlig förståelse för hur man genomför och tolkar ML- och MK-skattningar för exponentialfördelningar. Genom MATLAB har vi kunnat visualisera funktioner och se hur skattningar varierar vid upprepade mätningar. Resultaten överensstämmer med teorin, och visar tydligt hur skattningar konvergerar mot förväntat värde när stickprovsstorleken växer.